



MLBD Projet - Analogues climatiques

Quelles villes vivent aujourd'hui le climat passé et future de votre ville?

Abdellah Jahjah, Massimo Stefani, Eva Ray

17 janvier 2026
Lausanne
HES-SO MSE



Table des matières

- Introduction
- Description des données
- Pre-processing et feature extraction
- Techniques de machine learning
- Résultats
- Discussion
- Conclusion


Introduction

Changement climatique




Alpes bernoise: Glacier Grindelwald

En 2024, l'Europe aux avant-postes du désastre climatique



Analogue climatique




Description des données


Sources & Protocoles



ERA5 2 metre temperature and Mean sea level pressure
1 January 2023 at 00:00 UTC




Dioxyde de carbone en Gt par an




Variables Sélectionnées (Features)

- Température de l'air à 2 mètres de la surface
- précipitations totales: précipitations de pluie et de neige
- Chutes de neige
- Vitesse du vent à 10 mètres



Pre-processing et feature extraction

Sélection des villes





Traitement des variables climatiques

- **Nouvelles Features** : Création des Features Jours $> 30^{\circ}\text{C}$ et Jours consécutifs.
- **Standard OMM (30 ans)** : Climat défini sur 3 périodes (1940-1970, 1994-2024, 2020-2050).
- **Agrégation Saisonnière** : Moyennes calculées par saison sur l'ensemble de la période.
- **Normalisation** : Mise à l'échelle indispensable pour éviter les biais de pondération.



Réduction de dimensions

- **Curse of dimensionality:** Phénomène de pertes de performances lorsqu'on travaille en haute dimension. Lorsque la dimension augmente, le “volume” de l'espace augmente rapidement et les données deviennent clairsemées, menant à une dégradation des performances des algorithmes.
- Nous travaillons dans un espace de ***dimension 30*** et notre analyse repose sur des distances, il est donc indispensable de traiter ce problème.



Suppression des variables trop corrélées


- Suppression des variables fortement corrélées (>80%) avant d'appliquer PCA
- PCA cherche à capturer l'essentiel de la variance donc des variables fortement corrélées sont une information redondante.
- **9 Variables retenues:** 'sf_winter', 'sf_spring', 't2m_winter', 'tp_winter', 'tp_spring', 'si10_winter', 'temp_range_winter', 'temp_range_spring', 'hot_days'
 - Certaines corrélations attendues:

```
Feature 'max_t2m_winter' has high correlation (>0.8)
with: ['t2m_winter']
```

- Certaines features créées retenues: 'temp_range_winter', 'temp_range_spring', 'hot_days'

PCA

- Normalisation des 9 features avec un scaler entraîné sur les données historiques
- 4 PCAs retenues, expliquant 90,18% de la variance



Techniques de machine learning



Problème de la distance euclidienne

- Ne tient pas compte des corrélations et risque d'exagérer les différences sur les variables redondantes.
- **Exemple:** Soient 2 villes A et B avec les données climatiques suivantes
 - Température moyenne de janvier : différence de 2°C
 - Température min de janvier : différence de 2°C
 - Température max de janvier : différence de 2°C
 - **Distance** = $\sqrt{(2^2 + 2^2 + 2^2)} = \sqrt{12} \approx 3.46$
 - **Problème:** ces 3 variables sont très corrélées, il n'y a en fait qu'une variation climatique: le mois de janvier est plus chaud de 2°C.





Distance Mahalanobis

$$d_{M(x,y)} = \sqrt{(x - y)^T S^{-1} (x - y)}$$

- Tient compte de la corrélation entre les variables
- La matrice de covariance S^{-1} détecte que les variables corrélées et ajuste les poids
- Idéale pour les donnée climatique qui sont souvent fortement corrélées.

Encoder


- Autre technique de réduction de dimensions pour capturer des relations non linéaires
- Découpage en train et validation sets, normalisation calculée sur le train set.
- Encoder (30 - 32 - 4) et Decoder (4 - 32 - 30), 30 $\rightarrow$ nb features, 4 $\rightarrow$ nb PCAs
- Fonction d'activation tanh dans la couche cachée et linéaire en sortie
- On obtient une loss de 0.0405 (train) et 0.0564 (validation), sans d'overfitting



Résultats

Validation sans Ground Truth

Problématique: Il n'existe pas de Ground Truth.




Hypothèse de Validation:

La Translation Latitudinale.

Si le modèle est cohérent, les analogues du passé devraient présenter une tendance à se situer plus au nord, tandis que ceux du futur devraient se situer plus au sud.


Résultats en 1970



Divergences Méthodologiques

Bien que les moyennes diffèrent en fonction de la méthode employée, une tendance générale se dégage néanmoins.

Résultats en 2050



Consensus Méthodologique:

Peu importe la méthode utilisée, les résultats tendent vers un shift latitudinal moyen de -1.3°


Exemple - Paris 2050

Top 5 Analogs (SSP5-8.5 2050)
Orléans
Tours
Paris
Perpignan
Aix-en-Provence



Analyse & Discussion


Analyse du passé



- Les analogues climatiques se déplacent majoritairement vers le Nord
- Cette dynamique est cohérente avec le réchauffement climatique observé
- Les villes actuelles présentent des climats similaires à ceux de régions historiquement plus méridionales
- Peu de villes conservent un analogue identique
- La faible stabilité spatiale confirme un changement climatique réel et généralisé

Analyse du futur



FUTUR: Distribution des analogues climatiques - Mahalanobis (moyenne SSP126/370/585)



- Par rapport au passé, la tendance est nettement plus marquée dans le futur
- Les analogues climatiques se déplacent massivement, avec une dominance accrue vers le Sud
- La catégorie « analogue identique » est presque annihilée
- La stabilité climatique locale devient marginale, quelle que soit la méthode
- Cette accélération est cohérente avec l'intensification des scénarios climatiques futurs

Comparaison des méthodes

- **Futur:** résultats similaires, instabilités pour les embeddings, potentiellement dû à la capacité des autoencodeurs à capturer des relations non-linéaires complexes, qui pourraient mieux refléter les dynamiques climatiques futures.
- **Passé:** Résultats plus divergents, “all” montre une préférence pour les analogues au sud, peut être expliqué par la présence des variables corrélées, va à l’encontre de l’état de l’art.





Conclusion

Conclusion

Les villes européennes connaissent un « glissement » climatique vers le Sud.

Cela implique des changements géographiques significatifs pour :

- L'agriculture
- La santé
- Ressources en eau
- Les méthodes de construction, qui devront évoluer en conséquence.



Démonstration



Démonstration

Wi-Fi Network: Massimo

Password: hnay0078



Références