

Analogues climatiques en Europe

Quelle ville vit aujourd'hui le climat passé ou futur de votre ville ?

Machine Learning on Big Data
MSE

Eva Ray, Massimo Stefani, Abdellah Jahjah

14 Janvier 2026

Site de Provence, Lausanne

Table des matières

1. Contexte et objectifs	2
2. Database	2
3. Data pre-processing et feature extraction	2
3.1. Sélection des villes	2
3.2. Traitement des variables climatiques	2
3.3. PCA	3
4. Techniques de machine learning	3
5. Expériences et résultats	3
6. Analyses et conclusions	3
Bibliographie	4

1. Contexte et objectifs

Le changement climatique modifie profondément les conditions climatiques des villes. Des étés de plus en plus chauds, marqués par des vagues de chaleur prolongées, ainsi que des hivers moins froids et moins enneigés, sont désormais observés dans de nombreuses régions. Ces évolutions ont des conséquences importantes sur le confort urbain, la santé et les infrastructures, et rendent nécessaire une meilleure compréhension des effets du réchauffement climatique à l'échelle locale. Afin de rendre ces changements plus concrets et accessibles, ce projet s'appuie sur le concept d'analogues climatiques. Cette approche consiste à comparer le climat d'une ville à celui d'autres villes, à différentes périodes temporelles. Elle permet de répondre à des questions intuitives telles que : « Quelle ville possède aujourd'hui le climat que ma ville avait dans le passé ? » (backward analog) ou « Quelle ville possède aujourd'hui le climat que ma ville connaîtra dans le futur ? » (forward analog). L'objectif du projet est de développer un outil de visualisation, notamment sous forme de carte, permettant d'identifier ces analogues climatiques à partir de données climatiques historiques et de scénarios futurs. L'analyse se concentre au minimum sur les saisons estivale et hivernale. La similarité climatique est évaluée à l'aide de la métrique de Sigma-Dissimilarity, introduite par Fitzpatrick et al. (2019), qui repose sur la comparaison de vecteurs climatiques multidimensionnels et offre une mesure plus robuste que la simple comparaison des températures moyennes.

2. Database

Les données climatiques utilisées dans ce projet proviennent de sources reconnues au niveau international. Les données historiques sont issues du jeu de données ERA5, fourni par le Climate Data Store (CDS) du programme européen Copernicus et produit par l'ECMWF. ERA5 fournit des réanalyses climatiques cohérentes et de haute qualité, largement utilisées pour l'étude du climat passé et récent. Les projections climatiques futures reposent sur le projet CMIP6 (Coupled Model Intercomparison Project Phase 6), à travers le modèle climatique global IPSL-CM6A-LR, mis à disposition dans le cadre du protocole ISIMIP 3b. Ce modèle est couramment utilisé pour analyser les impacts du changement climatique et permet une comparaison cohérente entre différentes trajectoires d'émissions. Trois scénarios climatiques sont considérés : SSP1-2.6, SSP3-7.0 et SSP5-8.5, représentant respectivement des trajectoires optimiste, intermédiaire et pessimiste. Pour caractériser le climat local des villes étudiées, plusieurs variables météorologiques standard ont été sélectionnées. La température de l'air à 2 mètres (t2m) est utilisée pour représenter les conditions thermiques moyennes, ainsi que les extrêmes saisonniers à travers les températures maximales et minimales. Les précipitations totales (tp) permettent de décrire le régime hydrologique, tandis que les chutes de neige (sf) sont prises en compte afin d'analyser l'évolution de l'enneigement hivernal. Enfin, la vitesse du vent à 10 mètres (si10) est intégrée comme variable complémentaire caractérisant les conditions atmosphériques.

3. Data pre-processing et feature extraction

3.1. Sélection des villes

Les jeux de données initiaux couvrent une grille européenne ou mondiale, mais pour cette étude, l'analyse a été restreinte à un échantillon de 300 villes européennes, sélectionnées pour leur intérêt touristique [1]. L'extraction des features pour chaque ville a été réalisée en considérant un rayon de 50km ($\sim 0.45^\circ$) autour des coordonnées géographiques (latitude et longitude) de chaque ville, et en moyennant les valeurs des points de grille situés dans ce rayon. Après extraction, seulement 292 villes restent, les autres étant trop loin des points de grille disponibles dans les données climatiques.

3.2. Traitement des variables climatiques

Les données mensuelles brutes ont été transformées pour correspondre à l'échelle temporelle et saisonnière souhaitée. Les données historiques et les projections futures ont été fusionnées pour couvrir les périodes de 30 ans: 1940-1970 (passé), 1994-2024 (présent) et 2020-2050 (futur). Pour chaque

période, les variables ont été moyennées d’abord par saison, distinguant l’hiver (décembre à février), le printemps (mars à mai), l’été (juin à août) et l’automne (septembre à novembre), puis sur l’entièreté de la période de 30 ans. La période de 30 ans est choisie car c’est le nombre d’années minimal pour définir un climat, selon l’Organisation Météorologique Mondiale [2].




Fig. 1. – Transformation des données climatiques brutes en features saisonnières.

Enfin, les variables climatiques présentant des unités et des ordres de grandeur très différents, telles que la température en Kelvin, les précipitations en mètres ou la vitesse du vent en mètres par seconde, ont été normalisées pour éviter qu’une variable domine l’apprentissage. Cette standardisation a été effectuée à l’aide du StandardScaler, garantissant que chaque variable contribue de manière équilibrée lors de l’entraînement des modèles.

3.3. PCA

Pour limiter le « curse of dimensionality » affectant le calcul des distances, une Analyse en Composantes Principales (PCA) a été appliquée aux 9 features faiblement corrélées des données historiques. Cette réduction transforme les variables en un espace orthogonal conservant la majorité de la variance. Quatre composantes principales ont été retenues, expliquant 90.18% de la variance totale.




Fig. 2. – Variance expliquée en fonction du nombre de composantes principales retenues.

4. Techniques de machine learning

5. Expériences et résultats

6. Analyses et conclusions

Bibliographie

- [1] Rct567, « Cities of the world dataset ». [En ligne]. Disponible sur: <https://github.com/Rct567/Cities-of-the-world/>
- [2] C. national de compétences en matière de climat (NCCS), « Qu'est-ce que le climat ? ». [En ligne]. Disponible sur: <https://www.nccs.admin.ch/nccs/fr/home/changement-climatique-et-impacts/principes-de-base-du-climat/qu-est-ce-que-le-climat%E2%80%93.html>
- [3] M. C. Fitzpatrick et R. R. Dunn, « Contemporary climatic analogs for 540 North American urban areas in the late 21st century ». [En ligne]. Disponible sur: <https://www.nature.com/articles/s41467-019-08540-3>
- [4] B. Bulut, M. Vrac, et N. de Noblet-Ducoudré, « What Will the European Climate Look Like in the Future? A Climate Analog Analysis Accounting for Dependencies Between Variables ». [En ligne]. Disponible sur: <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2024EF004972>
- [5] C. C. C. S. (C3S), « ERA5 monthly averaged data on single levels from 1940 to present ». [En ligne]. Disponible sur: <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels-monthly-means>
- [6] C. C. C. S. (C3S), « ERA5 post-processed daily statistics on single levels from 1940 to present ». [En ligne]. Disponible sur: <https://cds.climate.copernicus.eu/datasets/derived-era5-single-levels-daily-statistics>
- [7] ISIMIP, « ISIMIP repository ». [En ligne]. Disponible sur: <https://data.isimip.org/search/>
- [8] S. Lange, « ISIMIP3b bias adjustment fact sheet ». 2021.

Pour la correction orthographique : OpenAI, ChatGPT (GPT-5) Model, San Francisco, CA, USA: OpenAI, 2025. [En ligne]. Lien: <https://chat.openai.com>