

Analogues climatiques en Europe

Quelle ville vit aujourd'hui le climat passé ou futur de votre ville ?

Machine Learning on Big Data
HES-SO MSE

Eva Ray, Massimo Stefani, Abdellah Jahjah

19 Janvier 2026

Site de Provence, Lausanne

Table des matières

1. Contexte et objectifs	2
2. Database	2
3. Data pre-processing et feature extraction	3
3.1. Sélection des villes	3
3.2. Traitement des variables climatiques	3
3.3. PCA	3
4. Techniques de machine learning	4
4.1. Distance Mahalanobis	4
4.2. Réduction de dimensionnalité par autoencodeur	4
5. Résultats	5
5.1. Exemple de résultat : Paris	5
5.2. Contexte de validation	5
5.3. Configurations analysées	5
5.4. Résultats : Translation latitudinale	6
5.4.1. Période passée (1970)	6
5.4.2. Comparaison passé-futur	6
6. Analyses et conclusions	6
6.1. Analyse de la translation latitudinale	6
6.1.1. Synthèse des résultats obtenus	6
6.1.2. Approfondissement : Analyse par ville individuelle	7
6.1.3. Comparaison des méthodes	7
6.2. Conclusion	7
Bibliographie	8
Annexes	9

1. Contexte et objectifs

Le changement climatique modifie profondément les conditions climatiques des villes. Des étés de plus en plus chauds, marqués par des vagues de chaleur prolongées, ainsi que des hivers moins froids et moins enneigés, sont désormais observés dans de nombreuses régions. Ces évolutions ont des conséquences importantes sur le confort urbain, la santé et les infrastructures, et rendent nécessaire une meilleure compréhension des effets du réchauffement climatique à l'échelle locale. [1], [2]

Afin de rendre ces changements plus concrets et accessibles au grand public, ce projet s'appuie sur le concept d'*analogues climatiques*. Un analogue climatique est une ville dont le climat actuel est similaire au climat passé ou futur d'une autre ville. Ce concept permet de répondre à des questions intuitives telles que : « Quelle ville possède aujourd'hui le climat que ma ville avait dans le passé ? » (backward analog) ou « Quelle ville possède aujourd'hui le climat que ma ville connaîtra dans le futur ? » (forward analog).

L'objectif du projet est d'identifier des analogues climatiques forward (2050) et backward (1970) pour un ensemble de villes européennes en utilisant des données historiques et des projections futures prétraitées pour extraire des caractéristiques climatiques pertinentes. Chaque ville est représentée par un vecteur climatique multidimensionnel, plus informatif qu'une simple moyenne de température. Les features reposent sur les moyennes saisonnières de variables clés telles que la température, les précipitations et la vitesse du vent. La similarité climatique est évaluée à l'aide de plusieurs métriques, dont la distance de Mahalanobis, qui intègre la covariance entre variables, et la distance euclidienne, utilisée comme référence. Les résultats seront visualisés via une carte interactive permettant aux utilisateurs d'explorer les analogues climatiques des villes européennes.

2. Database

Les données climatiques utilisées dans ce projet proviennent de projets reconnus au niveau international. Les données historiques sont issues du jeu de données **ERA5**, fourni par le *Climate Data Store* (CDS) du programme européen Copernicus et produit par l'ECMWF. ERA5 fournit des réanalyses climatiques cohérentes et de haute qualité, largement utilisées pour l'étude du climat passé et récent. [3] Deux datasets ont été utilisés, le premier avec des données moyennées mensuellement [4] et le second avec des données horaires [5], afin de pouvoir en extraire des variables plus spécifiques.

Les projections climatiques futures reposent sur le projet **CMIP6** (*Coupled Model Intercomparison Project Phase 6*), à travers le modèle climatique global **IPSL-CM6A-LR**, mis à disposition dans le cadre du protocole **ISIMIP 3b**. [6] ISIMIP 3b utilise une technique de « bias correction » qui consiste à comparer les données prédites par CMIP6 pour une période historique avec les données observées réelles, afin d'identifier les erreurs systématiques (ou biais) du modèle. Ces biais sont ensuite corrigés dans les projections futures pour améliorer leur précision. [7] Trois scénarios climatiques sont considérés : **SSP1-2.6**, **SSP3-7.0** et **SSP5-8.5**, représentant respectivement des trajectoires optimiste, intermédiaire et pessimiste.

Pour caractériser le climat local des villes étudiées, plusieurs variables météorologiques standard ont été sélectionnées :

- **Température de l'air à 2 mètres (t2m)** : température de l'air à 2m au-dessus de la surface, utilisée pour calculer les températures maximales et minimales journalières, le nombre de jours au dessus de 30°C par année, le nombre de jours consécutifs au dessus de 30°C par année et la différence entre les températures maximales et minimales journalières.
- **Précipitations totales (tp)** : somme des précipitations de pluie et de neige tombant à la surface terrestre
- **Chutes de neige (sf)** : neige accumulée tombant à la surface terrestre
- **Vitesse du vent à 10 mètres (si10)** : vitesse horizontale du vent à 10m au-dessus de la surface terrestre

3. Data pre-processing et feature extraction

3.1. Sélection des villes

Les jeux de données initiaux couvrent une grille européenne ou mondiale, mais pour cette étude, l'analyse a été restreinte à un échantillon de 300 villes européennes, sélectionnées pour leur intérêt touristique [8]. L'extraction des features pour chaque ville a été réalisée en considérant un rayon de 50km ($\sim 0.45^\circ$) autour des coordonnées géographiques (latitude et longitude) de chaque ville, et en moyennant les valeurs des points de grille situés dans ce rayon. Après extraction, seulement 292 villes restent, les autres étant trop loin des points de grille disponibles dans les données climatiques.

3.2. Traitement des variables climatiques

Les features « nombre de jours au dessus de 30°C » et « nombre de jours consécutifs au dessus de 30°C » ont été créées à partir des données journalières de température maximale. Pour chaque année, le nombre de jours où la température maximale dépasse 30°C a été comptabilisé, ainsi que le nombre maximum de jours consécutifs au dessus de ce seuil. Pour les données historiques, la température maximale journalière a été extraite des données horaires en prenant la valeur maximale sur chaque journée. Pour les projections futures, la température maximale journalière était déjà disponible.

Les données mensuelles brutes ont été transformées pour correspondre à l'échelle temporelle et saisonnière souhaitée. Les données historiques et les projections futures ont été fusionnées pour couvrir les périodes de 30 ans: 1940-1970 (passé), 1994-2024 (présent) et 2020-2050 (futur). Pour chaque période, les variables ont été moyennées d'abord par saison, distinguant l'hiver (décembre à février), le printemps (mars à mai), l'été (juin à août) et l'automne (septembre à novembre), puis sur l'entièreté de la période de 30 ans. La période de 30 ans est choisie car c'est le nombre d'années minimal pour définir un climat, selon l'Organisation Météorologique Mondiale [9].




Fig. 1. – Transformation des données climatiques brutes en features saisonnières.

Enfin, les features climatiques présentant des unités et des ordres de grandeur très différents, telles que la température en Kelvin, les précipitations en mètres ou la vitesse du vent en mètres par seconde, une normalisation est nécessaire pour éviter qu'une variable domine l'apprentissage.

3.3. PCA

Pour limiter le « curse of dimensionality » affectant le calcul des distances, une Analyse en Composantes Principales (PCA) a été appliquée pour réduire la dimension de l'espace des features. Avant la PCA, les features hautement corrélées (> 0.8) ont été supprimées pour éviter la redondance : pour chaque paire de features corrélées, une seule a été conservée. Ce filtrage a réduit le nombre de features de 30 à 9. Un scaler a été calculé sur ces 9 features des données historiques, puis appliqué aux données historiques et futures avant la transformation PCA. Quatre composantes principales ont été retenues, expliquant 90.18% de la variance totale.




Fig. 2. – Variance expliquée en fonction du nombre de composantes principales retenues.

4. Techniques de machine learning

4.1. Distance Mahalanobis

La distance de Mahalanobis permet de mesurer la similarité entre deux vecteurs climatiques en tenant compte des corrélations entre les variables, ce que ne fait pas la distance euclidienne. Elle évite ainsi d'exagérer les différences lorsque des variables sont fortement liées, ce qui est fréquent dans les données climatiques. La distance de Mahalanobis est définie comme suit, pour deux vecteurs x et y où S est la matrice de covariance des données :

$$d_{M(x,y)} = \sqrt{(x - y)^T S^{-1} (x - y)}$$

4.2. Réduction de dimensionnalité par autoencodeur

En complément de la PCA, nous avons exploré une méthode de réduction non-linéaire basée sur un autoencodeur MLP. Cette approche permet de capturer des relations complexes entre les variables climatiques que la PCA, limitée aux transformations linéaires, ne peut modéliser.

Les données d'entraînement sont les observations historiques fusionnées (1940-1970 et 1994-2024), qui ont été divisées en un ensemble d'entraînement (80%) et de validation (20%). Les données ont été normalisées avec un scaler entraîné uniquement sur l'ensemble d'entraînement pour éviter toute fuite de données. L'architecture consiste en un encodeur (30 - 32 - 4) et un décodeur symétrique (4 - 32 - 30), avec des activations tangente hyperbolique (tanh), pour capturer des relations non-linéaires, et une sortie linéaire. Le nombre de neurones de la couche cachée (32) a été choisi pour permettre de réorganiser l'information dans un espace plus riche tout en évitant l'overfitting. Il aurait été envisageable d'ajouter plus de couches cachées ou de neurones mais la performance était déjà satisfaisante avec cette architecture. La dimension de sortie de 4 a été choisie pour correspondre aux nombre de PCA, permettant une comparaison équitable des deux approches. Le modèle minimise l'erreur quadratique moyenne (MSE) entre les données d'entrée normalisées et leur reconstruction, en utilisant l'optimiseur Adam avec un taux d'apprentissage de 0.01.




Fig. 3. – Évolution de la perte (MSE) durant l'entraînement de l'autoencodeur.

L'entraînement converge vers une loss de 0.0405 (train) et 0.0564 (validation), indiquant une reconstruction fidèle et pas d'overfitting. L'encodeur entraîné a ensuite été appliqué aux projections futures (SSP126, SSP370, SSP585) en utilisant le même scaler, garantissant une représentation cohérente à travers toutes les périodes temporelles. Les embeddings générés constituent ainsi la deuxième méthode de réduction de dimensionnalité pour l'analyse des analogues climatiques.

5. Résultats

5.1. Exemple de résultat : Paris

Voici un exemple de résultats obtenus. Pour Paris, nous avons obtenu que la ville analogue climatique la plus proche est Orléans (voir Fig. 4). Cela signifie que le climat de Paris en 2021-2050 (selon le scénario SSP585) ressemblera au climat d'Orléans d'aujourd'hui.




Fig. 4. – Application interactive montrant les analogues climatiques de Paris pour la période 2021-2050 (scénario SSP585, méthode Embeddings, distance de Mahalanobis). Les 5 villes les plus proches sont : Orléans, Tours, Paris, Perpignan et Aix-en-Provence.

Toutefois, ce résultat est peu parlant : est-il juste ? Comment peut-on valider nos résultats sans données de référence ?

5.2. Contexte de validation

Dans le cadre de ce projet, nous nous trouvons dans une situation particulière : l'absence de « ground truth ». En effet, il n'existe pas de vérité absolue permettant de valider nos analogues climatiques, car le concept même d'analogie climatique est relatif et dépend des critères choisis.

Toutefois, suite à la lecture de plusieurs articles traitant des analogues climatiques ([1], [2]), nous avons identifié une métrique récurrente dans les études sur les analogues climatiques : la *translation latitudinale* des villes. En effet, l'état de l'art montre que les analogues climatiques backward (passé) ont tendance à se situer plus au nord des villes cibles, tandis que les analogues climatiques forward (futur) se trouvent plus au sud. Ainsi, cette métrique permet d'obtenir des chiffres quantitatifs sur nos résultats, sans pour autant constituer une validation absolue.

5.3. Configurations analysées

Notre analyse comparative porte sur 24 configurations différentes, résultant de la combinaison de :

- **3 méthodes de réduction de dimensionnalité** : Aucune (all features), PCA, Embeddings (autoencoder)
- **2 métriques de distance** : Euclidienne, Mahalanobis
- **4 périodes temporelles** : Passé (1970), Futur (2050) SSP126, SSP370, SSP585

5.4. Résultats : Translation latitudinale

5.4.1. Période passée (1970)

Méthode	Distance	Shift moyen (°)	% villes Nord
All features	Euclidienne	+0.10	46.2%
All features	Mahalanobis	−0.81	42.5%
PCA	Euclidienne	+0.28	48.6%
PCA	Mahalanobis	+0.20	49.0%
Embeddings	Euclidienne	+0.29	50.0%
Embeddings	Mahalanobis	+0.34	50.0%

Tableau 1. – Translation latitudinale moyenne des analogues climatiques pour la période 1970.

5.4.2. Comparaison passé-futur

Les résultats du passé montrent une tendance au déplacement vers le Nord des analogues climatiques. La Fig. 5 permet d’examiner si cette tendance se confirme pour les projections futures. Le graphique de gauche présente le passé (1970) et celui de droite le futur (2050, moyenne des scénarios SSP126, SSP370 et SSP585), chacun comparant les résultats obtenus avec les distances Euclidienne et Mahalanobis pour les trois approches.




Fig. 5. – Translation latitudinale moyenne par méthode et métrique de distance. Gauche : Période passée (1970). Droite : Période future (2050, moyenne des 3 scénarios SSP).

6. Analyses et conclusions

6.1. Analyse de la translation latitudinale

6.1.1. Synthèse des résultats obtenus

Les résultats présentés dans le chapitre précédent révèlent une migration climatique progressive vers le Sud au fil des décennies. Pour la période passée (1970), environ 48% des villes trouvent leurs analogues climatiques au Nord, suggérant déjà un début de réchauffement par rapport à des périodes antérieures. Les shifts moyens oscillent entre -0.81° et $+0.34^\circ$.

La Fig. 5 révèle que cette tendance s’accroît drastiquement pour la période future (2050). Les shifts deviennent majoritairement négatifs et la proportion de villes ayant leurs analogues au Sud augmente significativement. Ce glissement continu et accentué des zones climatiques vers le sud démontre la progression du réchauffement climatique projeté par les scénarios SSP : les climats européens « descendent » géographiquement, adoptant des caractéristiques de plus en plus méridionales.

6.1.2. Approfondissement : Analyse par ville individuelle

Les résultats précédents s'appuient sur la moyenne des 5 meilleurs analogues climatiques, offrant une vue d'ensemble. Pour affiner l'analyse, examinons maintenant le meilleur analogue unique de chaque ville.




Fig. 6. – Distribution des analogues climatiques par période. Chaque ville est classée selon son meilleur analogue : Stable (soi-même), Nord ou Sud. Distance Mahalanobis.

Pour le passé (1970), 22% en moyenne des villes européennes ont conservé un climat stable, leur meilleur analogue climatique est elles-mêmes. Les 78% restants se répartissent équitablement entre Nord et Sud, sans direction dominante.

Pour le futur (2050), la stabilité climatique s'effondre à en moyenne 7% : 93% des villes européennes auront un climat différent de leur climat actuel. La répartition Nord/Sud se déséquilibre : 38% Nord contre 54% Sud.

Le transfert est remarquable : la perte de 15 points de stabilité climatique (22% à 7%) correspond presque exactement au gain de 16 points vers le Sud (38% à 54%). Ce basculement symétrique démontre que les villes qui étaient climatiquement stables deviennent majoritairement des zones à climat « méridional ».

6.1.3. Comparaison des méthodes

Pour le futur, les trois méthodes de réduction de dimensionnalité produisent des résultats très similaires. Les embeddings montrent plus d'instabilités au profit d'analogues au Sud. Cela peut s'expliquer par la capacité des autoencodeurs à capturer des relations non-linéaires complexes, qui pourraient mieux refléter les dynamiques climatiques futures.

Pour le passé, les résultats divergent plus. Les embeddings identifient à nouveau plus de villes non stables et la méthode utilisant toutes les features montre une préférence pour les analogues au Sud, contrairement aux autres méthodes. Cela peut indiquer que les features corrélées éliminées capturent des nuances climatiques spécifiques à la période passée, qui orientent les analogues vers le Sud, contrairement à ce qui est attendu d'après l'état de l'art des analogues climatiques.

6.2. Conclusion

Ce projet a identifié des analogues climatiques pour les villes européennes en combinant données historiques et projections futures (scénarios GIEC). L'approche multi-méthodes (plusieurs techniques de réduction de dimensionnalité, deux métriques de distance, trois scénarios SSP) a permis d'observer une convergence des résultats malgré les différences techniques.

La tendance est claire : les villes européennes « descendent » climatiquement vers le Sud au fil du temps. Cette migration s'accroît entre les périodes passées (relativement stables) et futures (déplacement systématique vers des conditions méridionales), démontrant une transformation climatique à l'échelle européenne avec des implications majeures pour l'agriculture, les ressources en eau et les infrastructures urbaines.

Bibliographie

- [1] M. C. Fitzpatrick et R. R. Dunn, « Contemporary climatic analogs for 540 North American urban areas in the late 21st century ». [En ligne]. Disponible sur: <https://www.nature.com/articles/s41467-019-08540-3>
- [2] B. Bulut, M. Vrac, et N. de Noblet-Ducoudré, « What Will the European Climate Look Like in the Future? A Climate Analog Analysis Accounting for Dependencies Between Variables ». [En ligne]. Disponible sur: <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2024EF004972>
- [3] ECMWF, « ECMWF Reanalysis v5 (ERA5) ». [En ligne]. Disponible sur: <https://www.ecmwf.int/en/forecasts/dataset/ecmwf-reanalysis-v5>
- [4] C. C. C. S. (C3S), « ERA5 monthly averaged data on single levels from 1940 to present ». [En ligne]. Disponible sur: <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels-monthly-means>
- [5] C. C. C. S. (C3S), « ERA5 post-processed daily statistics on single levels from 1940 to present ». [En ligne]. Disponible sur: <https://cds.climate.copernicus.eu/datasets/derived-era5-single-levels-daily-statistics>
- [6] ISIMIP, « ISIMIP repository ». [En ligne]. Disponible sur: <https://data.isimip.org/search/>
- [7] S. Lange, « ISIMIP3b bias adjustment fact sheet ». 2021.
- [8] Rct567, « Cities of the world dataset ». [En ligne]. Disponible sur: <https://github.com/Rct567/Cities-of-the-world/>
- [9] C. national de compétences en matière de climat (NCCS), « Qu'est-ce que le climat ? ». [En ligne]. Disponible sur: <https://www.nccs.admin.ch/nccs/fr/home/changement-climatique-et-impacts/principes-de-base-du-climat/qu-est-ce-que-le-climat%E2%80%93.html>

Pour la correction orthographique : OpenAI, ChatGPT (GPT-5) Model, San Francisco, CA, USA: OpenAI, 2025. [En ligne]. Lien: <https://chat.openai.com>

Annexes

-.A. Carte des villes européennes sélectionnées

